

契约驱动的 Agentic Runtime

从三层责任架构，到可执行的 5W1H 数据使用契约

**能力可以迭代，容量可以扩展。
数据的身份、授权与证据必须始终可检查。**

研究状态：机制与合成验证已落地；真实任务和规模实验待完成

Yaxiao Liu · Pengbo Liu · Yiwon Liu · Yihua Guan · Zhenghe Hou · Jiaxing Song
PwC China AI Center / Tsinghua University

一个任务成功，不代表一个系统可管理

企业任务同时跨越业务、模型、基础设施和数据治理边界

业务问题

结果是否有用？
所有必需字段是否正确？
是否需要人工返工？

系统问题

容量变化是否改变行为？
失败能否恢复？
控制开销是否可接受？

数据问题

来源版本是否正确？
此刻是否仍有授权？
结论能否追到原始证据？

业务证据与运行时证据必须分别给出。

v29 将设计主张推进到可执行边界

01 责任契约

Skill / Harness / Scaffold
外部数据独立治理

架构设计

02 数据使用边界

5W1H+Which 谓词
执行期重验证与证据绑定

可运行的有限参考模型

03 可证伪评估

能力×容量交叉实验
质量、违规与总成本

确认性实验尚未执行

四个责任对象，三个运行时层

数据基座位于运行栈外，拥有独立的语义和治理权

Skill

可复用能力、输入输出、允许效果、版本

Harness

准入、图编排、策略检查、资源绑定、轨迹

Scaffold

计算、隔离、身份、地域、恢复与资源核算

外部数据基座

来源与快照

语义、授权、血缘

Data Wiki / Theme / IR

职责可以由同一团队实现，但契约边界仍需可检查。

P1：能力与容量是否能有条件分离？

研究的是交互效应、语义稳定性与控制成本

同一工作负载、模型、策略和源快照

$c0 \times s0$
 $R / Q / E$

$c0 \times s1$
 $R / Q / E$

$c1 \times s0$
 $R / Q / E$

$c1 \times s1$
 $R / Q / E$

每个单元同时观测

R：时延、吞吐、超时

Q：所有要求均满足的比例

E：准入、检查、证据处理开销

P1 仍未被本研究的真实运行时实验验证。

最小反例：列名相同，业务意义不同

示意场景；不是实测数据

来源 A：集团季度收入

字段：product_id, revenue

口径：集团合并 / USD / 2026 Q2

来源 B：子公司收入

字段：product_id, revenue

口径：本地公司 / EUR / 2026 Q1

检索相关、连接可执行，仍不代表可用于当前报告。

Data Wiki、Theme Wiki 与 IR 各回答什么

Data Wiki

这是什么数据？
来源、版本、字段、策略
可调用的读／抽取算子

IR

这次任务怎样使用？
5W1H+Which
证据、兼容性、回退

Theme Wiki

产出必须满足什么？
字段、单位、期间
质量要求与验证器

自然语言描述是元数据；原始来源与可信策略提供权威。

| 让 5W1H+Which 成为可检查条件

When	业务期间、有效期、当前时刻	排队后过期
Where	访问域与交付边界	内部数据外流
Who	可信身份与当前授权	准入后撤权
What	单位、实体范围、业务口径	同名异义
Why	批准的整合理由标识	编造连接理由
How	允许的算子和预算	读请求变成写
Which	关系、版本、键、血缘	错误关联或快照

字段存在不等于约束被执行。

从候选检索，到执行票据，再到证据



失败有类型：STALE / UNAUTHORIZED / SOURCE_CHANGED / REVALIDATE

撤权发生在排队期间：准入检查还够吗？

t0 准入

t1 撤销授权

t2 实际执行



策略 epoch = 7
生成票据

策略 epoch = 8
旧票据失效

重新检查
拒绝或重新准入

单机模型用锁；分布式适配器仍需实现一致性协议。

变更影响可沿显式依赖传播

源／策略变更

IR 失效

产物重验证

条件：依赖记录完整

隐藏视图、共享 prompt、latest 别名都可能破坏局部性

现状：保守失效

全局 epoch；不宣称细粒度维护成本已经降低

文件存在，仍不等于任务已完成

Theme 完成谓词

所有必需字段齐全
产物摘要与本轮匹配
证据依赖仍有效
指定验证器已通过

分别记录状态

已验证完成
部分完成
拒绝
过期，需要重验证

内容哈希证明字节身份；不证明事实为真或语义蕴含。

已经执行：有限契约一致性验证

一个收入记录 × 十个二值故障维度；穷举整个声明域

1,024

声明组合

1,023

预期拒绝

0

与 oracle 分歧

另有 5 项生命周期检查通过：撤权、替换、过期、重读、重验证

这是有限域一致性结果；不是检索质量或扩展性实验。

证据边界：我们现在可以说什么

可以说

数据边界有可运行规格
十维有限故障域已检查
五项生命周期检查通过
代码、逐例结果、哈希可检查

尚不能说

提高真实任务正确率
降低企业总成本
实现分布式安全或扩展性
P1 已成立或已达到顶会实证要求

近期工作：执行、研究与交付

Prime Agent

持久 REPL、递归会话、全树核算
迁移：固定总预算和持久状态
限制：高分不证明 P1

AutoResearch

独立评价与主张—证据绑定
迁移：结果必须对应真实产物
限制：示范案例非普适可靠性

Apodex 1.1

证据综合与受控产物交付
迁移：交付清单和时效验证
限制：其两轴与 P1 不同

近期工作：索引、路由与来源读取

VoiceMem

上层索引与后端分开

迁移：索引、路由分别消融

限制：检索时延非端到端时延

NeoHorse-1

预测需求 $\neq$ 实际执行路由

迁移：冻结模型并记录改路原因

限制：一次训练非持续自改进

Beyond Top-K

来源结构、单位和年份很关键

迁移：强 BM25 + 原文对照

限制：单文档小样本

v29 修正了哪些方法学风险

测量不足

覆盖、校准或区间不能判定 → inconclusive

义务明确失败

充分测量下违规超界 → conditional-engineering

义务全部通过

再按语义、交互、成本区间判断 P1

阈值与功效

阈值源自决策；p95 功效需要保留尾分布的模拟

下一步实验：隔离契约本身的作用

中心因果对照

A：保留来源的描述式目录
B：相同目录 + 执行契约
固定候选、工具、模型、预算
来源／模板／时间分组留出

一起报告

所有字段正确且证据有效
未授权／过期释放
合法任务误拒
构建 + 维护 + 在线总成本

另做强检索基线与逐维消融，避免把导航收益归因于治理。

内部试点：先选一个边界清楚的工作流

建议方案；尚未执行的内部试点

阶段 1：定义

选定输出字段与来源
明确单位、期间、授权
人工标注正确与拒绝案例

阶段 2：适配

接入一个真实读适配器
实现执行期重验证
用独立日志核查中介覆盖

阶段 3：比较

运行固定预算对照
报告误拒、质量与总成本
通过证据门槛后扩展范围

投稿方向由主贡献与实证决定

时间核查：2026-09-10；当前稿仍需补实证

SIGMOD / PACMMOD

数据契约、真实异构数据、维护成本

摘要 10/10；全文 10/17，AoE

OSDI 2027

完整运行时、独立监测、规模与故障实验

摘要 12/1；全文 12/8，22:59 UTC

ICSE / FSE

契约演进、变更影响、维护实证

ICSE 2027 已截止；FSE 日期未核实

先决定论文的主问题，再集中资源补齐对应证据。

内部讨论需要做的三个决定

01 选主问题

优先数据使用契约，还是完整能力—容量分离？

02 选证据场景

哪个真实工作流有明确来源、授权和可核验输出？

03 定验收条件

谁决定质量退化、误拒与总成本的可接受范围？

v29 的价值：把架构主张变成可执行、可追证、可被反驳的对象。

阅读与复现入口

五篇新增精读 + 一篇既有文献复核；全部采用原文链接

Prime Agent <https://arxiv.org/html/2608.23552v1>

AutoResearch <https://arxiv.org/html/2608.17906v1>

Apodex 1.1 <https://arxiv.org/html/2608.23283v1>

VoiceMem <https://arxiv.org/html/2608.26005v1>

NeoHorse-1 <https://arxiv.org/html/2609.08183v1>

Beyond Top-K <https://arxiv.org/html/2608.06305v1>

复现：artifact_v29/evaluate.py + test_contract.py
原始结果：fault-cases.csv / summary.json；P1 未评估